

ПРОГРАММИРОВАНИЕ НА ВИДЕОКАРТАХ

Начало

КАК ВСЁ ЭТО КОМПИЛИРОВАТЬ

Хост-код

.h файлы для C/C++ есть на официальном сайте, правда, там есть задепрекейченные полезные функции. Придётся задефайнить версию. Достаточно хедера `<CL/cl.h>`. Можно — `<CL/opencl.h>`

Чтобы слиноваться, надо где-то взять либы. Под линуксом — некий магический package. Под виндоусом — откуда-то взять. На официальном сайте Кроноса есть. Обратите внимание на битность!

ДЕВАЙС-КОД

Само разберётся. Обычно.

API

Большинство функций возвращают код ошибки (как обычно 0 — успешно, не 0 — не успешно). Надо проверять! Во всяком случае, в дебаге, в учебных целях. Написать макрос? Какой ужас.

Это за исключением функций типа create, которые возвращают то, что они create. Тогда код ошибки, если нужен, по ссылке, передаваемой в аргумент... Такой типичный C.

- `clGetPlatformIDs` — API для получения списка доступных платформ. Принимает... Указатель, размер, и указатель на размер... Буффер, размер буффера, и то, куда записывать, сколько.

Понятное дело, память она не выделяет. Так как надо, чтобы освобождал тот, кто выделил. Такой типичный C...

Так, а какого размера выделять буффер? Для этого есть специальный вариант вызова: `(nullptr, 0, &x)` — тогда в x нам запишут то, сколько на самом деле вариантов. Такой типичный C...

Правда, в отличие от типичного C, если буфера мало, то это не ошибка “буфера мало”, а нам запишут, сколько есть места.

Можно сказать, “возвращает” эта функция список id платформ, где можно запустить opencl.

TODO!

show rule 'типичный C'

TODO!

пояснения к коду

TODO!
getDeviceIDs

ДЕЛАЕМ ЧТО-ТО ПОЛЕЗНОЕ

Допустим, мы выбрали девайс, который нам нравится, с которым мы хотим работать.

Теперь нам нужно создать контекст.

- `clCreateContext`

Контекст — это своего рода `globalThis` от мира OpenCL. Он инкапсулирует в себе всё, что мы хотим из хост-кода делать с девайс-кодом.

Теперь нужно в этом контексте создать тот код, который мы будем запускать в этом контексте:

- `clCreateProgramWithSource`

“Принимает” массив указателей на `source`.

TODO!
Наебаться на сто дурных

Обычно мы хотим не извращаться с C-style строчками, а иметь отдельный файл с исходным кодом (обычно расширение `.cl`). То есть, надо открыть файл, прочитать и скормить (компиляция девайс-кода будет уже в рантайме). Предлагается использовать обычные C-шные функции `fread` и прочее. Открыть в `binary`, `seek` до конца и так далее. Типичный C...

Эта функция не делает ничего особенного. Если мы тут зафейлились, мы где-то конкретно налажали — передали кривой буфер или ещё что-нибудь. Ошибки внутри девайс-кода будут обнаруживаться уже потом.

- `clBuildProgram`

Вот это уже серьёзно: компиляция нашего исходника. Передаём сюда `id` нашего `program`’а, который мы по’create’или, и девайс, под который надо скомпилироваться. Или передать `null`, и тогда будет скомпилировано под все девайсы, привязанные к контексту.

Компиляция может занимать продолжительное время! Имеет смысл локально кэшировать. Но так как результат сильно зависит от драйверов, девайсов, версий, погоды, фазы луны; распространять прекомпилированную версию не имеет смысла.

Если в девайс-коде есть какая-нибудь синтаксическая (или ещё что-нибудь) ошибка, то она вылезет здесь. Обязательно проверять результат здесь! Можно сделать `clGetBuildInfo`, чтобы получить билд-лог (своего рода `compilation error`), ему нужно давать честный `id` девайса.

`build-options` — не должен быть `null`! Некоторые платформы могут его не пережить. Передайте пустую строчку. Или, лучше, используйте по назначению! Например, можно с помощью `-D` передавать дефайнами переменными.

НАКОНЕЦ, ДЕВАЙС-КОД

```
kernel void add(global const int *a, global const int *b, global int *c) {
    *c = *a + *b;
}
```

Здесь немного нового по сравнению с C.

- kernel означает, что это точка входа в программу. Их может быть несколько — это не совсем то же, что main.
- clCreateKernel — создаёт идентификатор, через который мы сможем вызывать kernel. Передаём туда имя.

Теперь мы хотим передать ему аргументы и запустить его! Проблемы? Э-э-э..... Указатели на память, что вы думаете, сработает? Ха. Где память? На девайсе. Мы её выделили? Нет. Очень жаль. Давайте выделять...

HERE WE GO AGAIN

- Выделяем память на девайсе: clCreateBuffer. Нам надо только передать размер буфера, и то, как мы хотим к нему обращаться из кернела (read only, write only, read-write). В данном случае, мы хотим три буфера: под a и под b — read-only, под c — write-only. Ну, мы можем оба подписать read-write, но лучше так — так что-нибудь оптимизировать (не надо про протокол когерентности, кэши, всё остальное думать).

Понятно, что доступ распространяется только на кернел, с хоста-то мы и так записать/прочитать сможем.

clCreateBuffer возвращает cl_mem, это своего рода указатель, но не указатель. Это хендл, арифметику с ним делать нельзя.

- А мы написали int... а что это? Понятное дело, что int на девайсе и int на хосте могут отличаться. Ну так для этого может быть cl_int. На самом деле, они даже фиксированы, не зависят от девайса. Так что это всегда 32 бита. Лучше, чем в C! А вот size_t девайса мы не знаем. Точнее, можем спросить, но это будет уже в рантайме и у конкретного девайса. Так что кернелам просто запрещено принимать size_t.
- Наконец, можем накормить кернел аргументами: clSetKernelArg, указываем туда идентификатор кернела, номер аргумента, значение аргумента (оно — как адрес + количество байтов).
- В наших буферах лежит какой-то мусор, надо его наполнить. clEnqueueWriteBuffer. Чувствуется в названии подвох.
- clCreateCommandQueue — очередь команд, чего мы хотим. Принимает контекст и девайс. А ещё принимает *флажки*. Один из них полезный — profiling info (или как-то так), причём почти ничего не стоит. Рассказывает, сколько времени уходит на процессы. Второй — out of order executionary order. Не влезай, убьёт.
- clEnqueueWriteBuffer, да. Принимает cl_mem, указатель наш (откуда брать данные), флажок blocking write (позже). Про блокирующее чтение. Мы ставим *задание на постановку в очередь*. Если мы не поставим флажок, то оно вернётся мгновенно! И ничего не дожждётся. Имеет смысл делать передачу данных **на** девайс не блокирующей, а **с** девайса — блокирующей. Очередь ленивая, не будет ничего исполнять, пока мы не пнём её. Ну, или можно пнуть через “*подождать выполнения всех функций*”. Или спросить “*а не в омах ли измеряется сопротивление а не закончилось ли исполнение*”.

- Спойлер: В конце захотим `clEnqueueReadBuffer`.
- `clEnqueueNDRangeKernel` — урааа! Запуск кернела. Передаём туда, очевидно, очередь и кернел. Принимает также `dimensions` (who? пока передаём 1); `global work size`, причём через указатель (пока тоже 1); `local work size` — смело кормим `null`'ами, так же поступаем с `event`'ами.
- Наконец, делаем `clEnqueueReadBuffer`, и читаем нашу замечательную сумму двух чисел. Будем на это, во всяком случае, надеяться.
- Замечание к окончанию: всё, что мы `create`, хорошо бы потом `release`. А то может быть грустно.
- А если что-нибудь криво работает на девайсе... Ну, упадёт видео-драйвер. Винда его обычно поднимает через пару секунд, остальные — ... поэкспериментируйте!